






Eksploracja danych

Laboratorium – analiza skupień



Analiza skupień

- Analiza niejednorodnych zbiorów danych
- Identyfikacja grup obiektów podobnych do siebie
 - Jednorodność w obrębie grupy
 - Różnorodność pomiędzy grupami
- Opis uzyskanych segmentów




Analiza skupień - zastosowanie

- Grupy sprzedażowe (profile klientów, profile produktów)
- Grupy ryzyka np. kredytowego, zdrowotnego
- Segmentacja rynku
- Określenie jednorodnych grup do dalszych analiz
- ...




Analiza skupień


- Niejednorodna grupa metod
- Grupowanie niehierarchiczne
 - Metoda k-średnich
 - GMM
 - DBSCAN
- Grupowanie hierarchiczne
 - Metoda aglomeracyjna
- Sieci neuronowe Kohonena




K-średnich




Algorytm k-średnich




Algorytm k-średnich




Algorytm k-średnich




Algorytm k-średnich




Algorytm k-średnich




Algorytm k-średnich




Algorytm k-średnich




Algorytm k-średnich





Inne wybrane algorytmy



GMM





GMM



Hierarchiczna analiza skupień

Diagram drzew a
Metoda Warda
Odległ. euklidesowa




Hierarchiczna analiza skupień

- Różne miary odległości
 - Euklidesowa, kwadrat odległości euklidesowej, Manhattan
- Różne sposoby mierzenia odległości
 - W tym najbardziej efektywna metoda Warda
- Określenie punktu odcięcia
 - Maksymalny iloraz odległości aglomeracyjnych
 - Pierwszy wyraźny przyrost odległości aglomeracyjnej




Sieci Kohonena



Uczenie sieci Kohonena

- uczenie sąsiadów




$$w(t+1) = w(t) + \alpha (x(t) - w(t))$$


w początkowej fazie uczenia sąsiedztwo obejmuje wszystkie neurony warstwy wyjściowej; w trakcie uczenia promień sąsiedztwa ulega zmniejszeniu; w końcowej fazie uczony jest tylko neuron zwycięski

Sieci Kohonena

- wprowadzenie danych
- wybór neuronu zwycięskiego
- uczenie neuronu zwycięskiego




$$w(t+1) = w(t) + \alpha (x(t) - w(t))$$




Sieci Kohonena

- W początkowej fazie uczenia sąsiedztwo obejmuje wszystkie neurony warstwy wyjściowej
- w trakcie uczenia promień sąsiedztwa ulega zmniejszeniu
- w końcowej fazie uczonej jest tylko neuron zwycięski




$$w(t+1) = w(t) + \alpha (x(t) - w(t))$$




Sieci Kohonena

- Nieliniowe mapowanie
- Każdy neuron reprezentuje pojedyncze skupienie
 - Opis uzyskanych segmentów
- Neurony tworzą mapę
 - Zrozumienie relacji pomiędzy skupieniami



DBSCAN

Clustering with
DBSCAN...



...Clearly Explained!!!

9:30

BAM!!!

Hello!!! I'm
StatSquatch!!! But
you can call me
'Squatch!

And I'm
Normalsaurus, but
you can call me
Norm.

And I'm Josh
but you can call me
Norm.
Together, we're going to learn
Data Science, Statistics and
Machine Learning, one step
at a time!!!

DOUBLE
BAM!!!

StatQuest with Josh Starmer

@statquest · 1,36 mln subskrybentów · 287 filmów

Statistics, Machine Learning and Data Science can sometimes seem like very scary topics...więcej

patreon.com/statquest i jeszcze 4 linki

Subskrybujesz

Wesprzyj




Przepis na model

Przygotowanie danych

Najważniejsze zasady

- Nie ma najlepszej metody analizy skupień
- Najlepszą metodę (dla naszych danych) wyłaniamy empirycznie
- Działamy na zasadzie prób i błędów
- Zrozumienie danych i problemu jest kluczowe
 - Znaczenie merytoryczne
 - Rozkłady
- Czyszczenie danych czyli **jak sobie pościelisz tak się**




wyśpisz





Zrozumienie danych

- Czym jest jeden wiersz (transakcja, klient, pacjent)
- Na jakich skalach pomiarowych mierzone są zmienne?
- Jak zostały zebrane?
- Jakie jest znaczenie merytoryczne danych, zmiennych?



Badanie rozkładów zmiennych

- Zmienne ilościowe
 - Liczba różnych wartości
 - Odsetek braków danych
 - Analiza rozkładów
 - Identyfikacja wartości odstających
 - Podsumowanie podstawowych statystyk



	sepal length (cm)	sepal width (cm)	petal length (cm)	petal width (cm)
count	150.000000	150.000000	150.000000	150.000000
mean	5.843333	3.057333	3.758000	1.199333
std	0.828066	0.435866	1.765298	0.762238
min	4.300000	2.000000	1.000000	0.100000
25%	5.100000	2.800000	1.600000	0.300000
50%	5.800000	3.000000	4.350000	1.300000
75%	6.400000	3.300000	5.100000	1.800000
max	7.900000	4.400000	6.900000	2.500000




Badanie rozkładów zmiennych

- Zmienne jakościowe
 - Histogram
 - Tabela licznosci
- Rzadkie klasy
- Pomyłki
- ...





Wymagania analizy skupień

- Wartości odstające (outliers):
 - Mogą silnie zniekształcać wyniki wielu metod analizy skupień (szczególnie k-średnich i hierarchicznych)
 - Powinny zostać wykryte i ocenione przed wykonaniem analizy skupień
 - Wymagają decyzji: usunięcie, osobna analiza, transformacja danych lub zmiana metody
- Metody gęstościowe (np. DBSCAN) naturalnie traktują je jako szum, a nie jako element skupień



Wartości odstające

- Przycinamy (winsoryzacja) do zakresu nieodstających
- Na podstawie reguły Tukeya (rozstęp kwartylowy * 1,5)



Wymagania analizy skupień

- Braki danych
 - Większość algorytmów klasteryzacji wymaga danych kompletnych (bez braków)
 - Przed analizą należy zidentyfikować i ocenić skalę braków danych
 - Wymagana jest decyzja: usunięcie obserwacji / zmiennych lub uzupełnienie braków
 - Sposób postępowania z brakami danych może istotnie wpłynąć na wynik analizy



Braki danych

- Strategie uzupełniania zależą od
 - Skali pomiarowej
 - Odsetka braków
 - Preferencji badacza

Tabela 2.1. Techniki uzupełniania braków danych w podziale na odsetek braków i skalę pomiarową


Odsetek braków danych	Skala ilościowa	Skala jakościowa
Do 5%	Mediana Średnia	Modalna
Od 5% do 95%	Dyskretyzacja zmiennej oraz dodanie kategorii „brak” KNN	Dodanie osobnej kategorii „brak” KNN
Pow. 95%	Zmienna dychotomiczna „brak” / „nie brak”	Zmienna dychotomiczna „brak” / „nie brak”

Źródło: opracowanie własne.



Wymagania analizy skupień

- Skala i zakres zmiennych
 - Większość algorytmów opiera się na porównywaniu odległości między obiektami
 - Zmienne o dużym zakresie wartości mogą zdominować wartość obliczanej odległości
 - Zmienne powinny mieć porównywalne skale (np. standaryzacja, normalizacja)
 - Brak skalowania może prowadzić do błędnych lub mylących wyników analizy



Przekształcanie danych (standaryzacja / normalizacja)



- Gdy w różnych jednostkach (km, lata, osoby itp.)
- Gdy różny zakres zmiennych (różny rząd wielkości)
- Normalizacja – sprowadzenie zmiennych do wartości z przedziału $[0,1]$

$$x_{ij}^* = \frac{x_{ij} - \min\{x_{ij}\}}{\max\{x_{ij}\} - \min\{x_{ij}\}}$$




Skalowanie

- Skalowanie do zakresu [0,1]




Wymagania analizy skupień

- Brak korelacji pomiędzy zmiennymi
- Silnie skorelowane zmienne wprowadzają redundancję informacji i mogą zaburzać wartość obliczanej odległości – wielokrotnie liczymy tę samą informację




Wymagania analizy skupień

- Ocena korelacji pomiędzy zmiennymi
- **Selekcja** zmiennych przed analizą
- Metody redukcji wymiaru (np. PCA)
 - wtedy analizę robimy na **składowych**, a nie na danych surowych




Wymagania analizy skupień

- Czy PCA jest dobrym rozwiązaniem?
- Czy dane są dostatecznie ze sobą skorelowane?
- Test Bartletta, kryterium KMO
- Liczba składowych = liczba zmiennych do analizy skupień



Wymagania analizy skupień (k-średnich)

- Najlepiej gdy skupienia mają sferyczny kształt, są podobnej wielkości i gęstości
- Nie działa najlepiej dla skupień o nieregularnych kształtach
- Zazwyczaj z góry nie wiemy, jaki jest kształt skupień
- Alternatywne metody: DBSCAN, GMM (Gaussian Mixture Models)





Przepis na model

Optymalizacja i ocena modelu


Na czym może polegać ocena? optymalizacja?

- Czy model jest dobry? – ocena
- Czy można zbudować lepszy? – optymalizacja




Na czym może polegać ocena? optymalizacja?

- Jak zbudować inny model?
 - Zmiana ustawień (hiperparametrów) metody
 - Najczęściej liczba skupień
 - Inne ustawienia
 - Zmiana metody
- Jak ocenić model?
 - Miary jakości dopasowania
 - Stabilność wyników
 - Sensowność interpretacji (subiektywna)




Identyfikacja modelu

- Identyfikacja modelu wiąże się z procesem identyfikacji liczby skupień choć liczba skupień nie musi być jedynym hiperparametrem wpływającym na jakość modelu



Ocena uzyskanej klasyfikacji

- Brak jednego „dobrego” wskaźnika w sposób syntetyczny opisującego dobroć dopasowania modelu, używanych jest kilkadziesiąt konkurencyjnych wskaźników (zatem zapewne nie ma żadnego dobrego)




Inercja

- Jeden z najprostszych wskaźników
- Jak dobrze dany punkt pasuje do swojego skupienia
- Własności
 - Mierzy sumę kwadratów odległości punktów od skupień, do których należą
 - Wartość maleje wraz ze wzrostem liczby skupień
 - Można wykorzystać wykres łokciowy do znalezienia optymalnej liczby skupień
 - Nie ma progów, jedynie do porównań




Inercja

- Jeden z najprostszych wskaźników
- Jak dobrze dany punkt pasuje do swojego skupienia
- Wymagania
 - Powinno się go używać dla wyskalowanych danych
 - Nie ocenia odległości między skupieniami – może preferować wiele małych skupień
 - Skupienia mają kształt sferyczny (w przybliżeniu)



Inercja



Wskaźnik sylwetki

- Jak dobrze dany punkt pasuje do swojego skupienia (spójność)
- Jak dobrze jest odseparowany od punktów w innych skupieniach (separacja)

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$$


- $a(i)$ – średnia odległość obiektu i od obiektów własnego skupienia
- $b(i)$ – średnia odległość obiektu i od obiektów z najbliższego skupienia (liczonego po punktach a nie wg środka)

Wskaźnik sylwetki

- Wartość wskaźnika dla danego punktu mieści się w zakresie od -1 do 1 :
 - Blisko 1 : Punkt jest dobrze dopasowany do swojego skupienia i daleko od innych
 - Blisko 0 : Punkt leży na granicy dwóch skupień
 - Blisko -1 : Punkt prawdopodobnie został źle przypisany i należy do innego skupienia
- Im wyższa **średnia** wartość wskaźnika sylwetki dla całego zbioru, tym lepszy model


Wskaźnik sylwetki

- Wykres przedstawia wartości wskaźnika sylwetki dla poszczególnych przypadków
- Wysokie słupki oznaczają dobre dopasowanie
- Niskie lub ujemne wartości – problem z dopasowaniem
- Spójne wartości – jednorodne skupienie
- Szeroki zakres wartości – wewnętrzne różnicowanie




Wskaźnik sylwetki

- Jeśli niektóre skupienia mają niskie średnie wartości współczynnika sylwetki lub występują wartości ujemne, warto rozważyć zmianę liczby skupień w modelu



Wskaźnik sylwetki

- Interpretacja (reguły „kciuka”)
 - 0,70+ – bardzo dobra struktura skupień
 - 0,50 – 0,70 – dobra struktura skupień
 - 0,25 – 0,50 – słaba/umiarkowana struktura
 - Poniżej brak wyraźnej struktury lub błędne przypisania



Dodatkowe miary

- Wskaźnik Calińskiego-Harabasza
 - Mierzy proporcję różnorodności międzygrupowej do różnorodności wewnątrzgrupowej
 - Im większa wartość, tym lepiej
- Wskaźnik Dunna
 - Określa jakość skupień, uwzględniając minimalną odległość między skupieniami w stosunku do ich maksymalnej średnicy
 - Im większa wartość tym lepiej

Dodatkowe miary

- Wskaźnik Hartigana
 - Szukamy najmniejszej liczby skupień, dla której wartość wskaźnika spada poniżej 10
 - Jeśli takiej liczby nie ma, wybieramy liczbę skupień, dla której różnica wartości wskaźnika między kolejnymi skupieniami jest najmniejsza
- Wskaźnik **Daviesa-Bouldina**
 - Im mniejsza wartość tym lepiej
- Wskaźnik Krzanowskiego-Lai
 - Im większa wartość tym lepiej

ARI – Adjusted Rand Index

- Określanie zgodności pomiędzy dwoma modelami
 - Mamy modele utworzone za pomocą dwóch metod (np. k-średnich oraz sieci Kohonena) i chcemy ocenić zgodność wyników
 - Określanie zgodności między modelem, a znanym „poprawnym”, referencyjnym wynikiem
- Sprawdza, czy dwa obiekty, które są razem w jednym podziale, są też razem w drugim podziale?

ARI – Adjusted Rand Index

- ARI przyjmuje wartości od -1 do 1 :
 - 1 : Idealne dopasowanie wyniku modelu z referencyjnymi etykietami
 - 0 : Dopasowanie na poziomie losowego przypisania
 - < 0 : Wynik gorszy niż losowy (rzadkie przypadki, np. całkowicie odwrotne przypisanie skupień)


Optymalizacja - Ile segmentów?

- Najtrudniejsza część analizy
 - Względy pragmatyczne
 - Interpretacja wyników
- Stosowanie wyników w praktyce
- Występowanie w danych naturalnych skupień



Optymalizacja - Ile segmentów?



- Kilka rozwiązań może być równie poprawnych
- Wymaga podejmowania subiektywnych decyzji
- Segmentacja talii kart na 2 i 4 skupienia




W jaki sposób znaleźć model GE (Good Enough)

- Budowa wielu modeli na podstawie różnych ustawień i metod
- Ocena i porównanie wyników na podstawie
 - Inercji (wykres łokciowy) – liczba skupień
 - Indeksu sylwetkowego – liczba skupień, metoda
 - Innych preferowanych miar
 - Subiektywnej oceny

W jaki sposób znaleźć model GE (Good Enough)




W jaki sposób znaleźć model GE (Good Enough)




W jaki sposób znaleźć model GE (Good Enough)

- Analiza aglomeracji



Znajdź pierwszy „wyraźny” skok odległości wiązania




Dla tej odległości wiązania mamy 3 skupienia


Czy uzyskany wynik jest stabilny?

- Losujemy wiele prób bootstrapowych z danych (np. 100), aby zasymulować drobne zakłócenia w zbiorze uczącym
- Dla każdej próbki trenujemy osobny model, ale predykcję etykiet wykonujemy zawsze na oryginalnym zbiorze danych
- Porównujemy etykiety skupień z każdego modelu do modelu referencyjnego (uczonego na pełnym zbiorze) za pomocą Adjusted Rand Index (ARI)
- Histogram ARI pokazuje rozkład wyników — im wyższe wartości i mniejsze odchylenie, tym bardziej stabilny jest model analizy skupień


Czy uzyskany wynik jest stabilny?



Czy uzyskany wynik jest stabilny?



Przebieg procesu modelowania



Jaka metoda

- Hierarchiczna
 - Brak założeń dotyczących liczby skupień
 - Stabilne wyniki
 - Mało użyteczna dla dużych zbiorów
- Niehierarchiczne oraz SOM
 - Konieczność określenia liczby skupień
 - Środki skupień są naturalnymi „typowymi” przedstawicielami swoich skupień



Jaka metoda

- DBSCAN
 - Zależna od dodatkowych hiperparametrów
 - Niewrażliwa na wartości odstające
 - Dowolny kształt skupień
- O czym należy pamiętać?
 - Wrażliwość metod na wartości odstające
 - Wrażliwość na zmienne o różnym zakresie zmienności




Zadania



Zadania

- Do wyboru kilka zbiorów danych
 - Wykonanie jednego zadania – maksymalna ocena 3.0
 - Wykonanie dwóch zadań – maksymalna ocena 4.0
 - Wykonanie trzech zadań – maksymalna ocena 5.0
-
- Poza samymi wynikami należy przedstawić **interpretację** uzyskanych wyników




Zadania

Zbiór irysy




Dane - irysy


Iris setosa



Iris versicolor



Iris virginica



- Eksploracyjna analiza
- Model uczony w trybie bez nauczyciela



Dane: Irisdat.sta* (5 zmn. * 150 prz.)

Dane Fishera (1936) o irysach: długość i szerokość działek kielicha i płatków, 3 c

	1	2	3	4	5
	Dł działki	Szer działki	Dł płatka	Szer płatka	Odmiana
1	5,0	3,3	1,4	0,2	SETOSA
2	6,4	2,8	5,6	2,2	VIRGINIC
3	6,5	2,8	4,6	1,5	VERSICOL
4	6,7	3,1	5,6	2,4	VIRGINIC
5	6,3	2,8	5,1	1,5	VIRGINIC
6	4,6	3,4	1,4	0,3	SETOSA
7	6,9	3,1	5,1	2,3	VIRGINIC
8	6,2	2,2	4,5	1,5	VERSICOL
9	5,9	3,2	4,8	1,8	VERSICOL
10	4,6	3,6	1,0	0,2	SETOSA
11	6,1	3,0	4,6	1,4	VERSICOL
12	6,0	2,7	5,1	1,6	VERSICOL
13	6,5	3,0	5,2	2,0	VIRGINIC
14	5,6	2,5	3,9	1,1	VERSICOL
15	6,5	3,0	5,5	1,8	VIRGINIC
16	5,8	2,7	5,1	1,9	VIRGINIC
17	6,8	3,2	5,9	2,3	VIRGINIC
18	5,1	3,3	1,7	0,5	SETOSA
19	5,7	2,8	4,5	1,3	VERSICOL
20	6,2	3,4	5,4	2,3	VIRGINIC
21	7,7	3,8	6,7	2,2	VIRGINIC
22	6,3	3,3	4,7	1,6	VERSICOL
23	6,7	3,3	5,7	2,5	VIRGINIC
24	7,6	3,0	6,6	2,1	VIRGINIC
25	4,9	2,5	4,5	1,7	VIRGINIC

Zbiór irysy

- Zapoznaj się z notatnikiem Jupyter z przykładowym rozwiązaniem dla analizy skupień
- **Zadanie 1** – Porównanie różnych metod analizy skupień (szczegóły w notatniku)
- **Zadanie 2** – Ocena stabilności wyniku analizy skupień



Zadania

Zbiór składniki



Zbiór składniki

- Zbiór zawiera produkty spożywcze opisane przez zawartość różnych składników odżywczych, takich jak białko, tłuszcz, węglowodany, składniki mineralne i witaminy
- **Zadanie 3** – Samodzielna analiza skupień produktów spożywczych
- **Zadanie 4** – Analiza skupień po redukcji wymiarów





Zadania

Zbiór marketing

Zbiór marketing

- Zbiór zawiera informacje o klientach kampanii marketingowej
- **Zadanie 5** – samodzielna segmentacja klientów



Zbiór marketing – zmienne

- ID – identyfikator klienta
- Year_Birth – rok urodzenia
- Education – poziom wykształcenia klienta
- Marital_Status – stan cywilny klienta
- Income – roczny dochód gospodarstwa domowego klienta
- Kidhome – liczba małych dzieci w gospodarstwie domowym
- Teenhome – liczba nastolatków w gospodarstwie domowym
- DtCustomer – data rejestracji klienta w firmie
- Recency – liczba dni od ostatniego zakupu




Zbiór marketing – zmienne

- MntWines–kwota wydana na wino w ciągu ostatnich 2 lat
- MntFruits–kwota wydana na produkty owocowe w ciągu ostatnich 2 lat
- MntMeatProducts–kwota wydana na produkty mięsne w ciągu ostatnich 2 lat
- MntFishProducts–kwota wydana na produkty rybne w ciągu ostatnich 2 lat
- MntSweetProducts–kwota wydana na produkty słodkie w ciągu ostatnich 2 lat
- MntGoldProds–kwota wydana na produkty ze złota w ciągu ostatnich 2 lat


Zbiór marketing – zmienne

- NumDealsPurchases–liczba zakupów dokonanych z rabatem
- NumWebPurchases–liczba zakupów dokonanych przez stronę internetową firmy
- NumCatalogPurchases–liczba zakupów dokonanych za pomocą katalogu
- NumStorePurchases–liczba zakupów dokonanych bezpośrednio w sklepach
- NumWebVisitsMonth–liczba wizyt na stronie internetowej firmy w ostatnim miesiącu



Zbiór marketing – zmienne

- AcceptedCmp1 –1 jeśli klient zaakceptował ofertę w 1. kampanii, 0 w przeciwnym razie
- AcceptedCmp2, AcceptedCmp3, AcceptedCmp4, AcceptedCmp5 –analogicznie
- Complain–1 jeśli klient złożył reklamację w ciągu ostatnich 2 lat
- Z_CostContact–koszt kontaktu
- Z_Revenue–zysk z kontaktu
- Response–akceptacja oferty



Powodzenia!